

TxBizFinder Intelligence

Roadmap: lo que falta + APIs publicas + scraping

Generado 2026-07-21 | Suite Texas SaaS

1. Resumen ejecutivo

Este documento describe (1) que falta implementar para convertir la suite en un SaaS creíble frente a portales tipo FEMA/aseguradoras, (2) de donde obtener datos con APIs públicas (preferido: mayor validación y estabilidad), y (3) donde el scraping es necesario o útil como fallback, con riesgos legales y técnicos.

Principio de diseño: API oficial o open data > bulk CSV/geospacial > scrape HTML. Nunca scrapear en el request del usuario; siempre workers (CLI + cron/Actions).

Apps de la suite y puertos locales

- MapHub Texas (command center): <http://127.0.0.1:3015>
- FloodGuard Texas: <http://127.0.0.1:3013>
- PowerPulse Texas: <http://127.0.0.1:3014>
- PermitRadar Houston: <http://127.0.0.1:3010>
- ChannelWatch: <http://127.0.0.1:3011>
- Emissions Sentinel API: <http://127.0.0.1:8001>
- TxBizFinder API: <http://127.0.0.1:8000>

Estado actual (ya implementado)

- FloodGuard: NWS live alerts (api.weather.gov) + demo risk por ZIP + boost híbrido
- PowerPulse: demo ERCOT-style + ZIP3 -> region
- MapHub: multi-layer + </api/suite/overview> (Texas pulse)
- PermitRadar: permisos Houston (xlsx) + multi-city open data (ingest CLI)
- ChannelWatch: live Open-Meteo/NOAA/NWS + ingest TCEQ/AirNow opcional
- Emissions Sentinel: warehouse multi-source + anomalías (demo fallback fuerte)
- TxBizFinder: franchise tax + TABC join + research web Playwright
- Contratos suite: </api/health> y </api/suite/meta> en productos Nuxt

2. Lo que FALTA implementar (backlog priorizado)

P0 - Credibilidad comercial (4-8 semanas)

Gateway SaaS

api.txbizfinder.com con API keys, rate limits por tier (Free/Contractor/Pro/Enterprise), billing Stripe.

Auth unificada

Clerk o Supabase Auth para seats humanos; API keys para maquinas; rotar admin-dev-key.

FEMA NFHL

Poligonos SFHA oficiales en FloodGuard Pro (FeatureServer/WMS). Diferenciador vs demo.

OpenFEMA NFIP

Claims/density por ZIP para narrativa aseguradoras (no cotizacion).

EIA + AirNow keys

Energia y AQI reales en PowerPulse/Channel/Sentinel (registro free).

Envelope + OpenAPI

Respuesta estandar {data, meta} y OpenAPI por producto + gateway.

Legal/ToS

Disclaimers fuertes: no FEMA determination, no insurance advice, no ERCOT ops.

P1 - Datos y producto (siguiente sprint)

USGS NWIS gauges

Caudales/rios en mapa flood/channel.

CAMPD + GHGRP + eGRID bulk

Capas industriales para underwriting / Sentinel.

ERCOT public feeds

Reemplazar demo de PowerPulse (revisar terminos de uso).

TCEQ GIS services

Inventarios y capas TX estables vs scrape HTML fragil.

Alertas Contractor

Saved ZIP, email/SMS digest de permisos y flood watches.

Webhooks Pro

Nuevo permiso por ZIP/tag; anomalia high en facility.

Tests + CI smoke

pytest + health checks suite overview en Actions.

P2 - Escala SaaS

- MCP server + CLI (npx txbiz) estilo World Monitor
- SDK TypeScript/Python thin clients
- White-label MapHub + SSO Enterprise
- Bulk geocode + parcel join (seguros)
- Monorepo packages compartidos (@txbiz/suite-meta, map tokens)

3. APIs publicas - MAYOR VALIDACION (preferir)

Estas fuentes tienen documentacion oficial, SLAs implícitos de agencia, o contratos de open data. Usar primero. Validacion: schema estable, auth documentada, historico, citables en disclaimers.

3.1 Inundacion / clima / hidrologia

Fuente	Auth	Uso	Estado suite	Validacion
NWS api.weather.gov	Free + User-Agent	Alertas activas TX	FloodGuard [OK] live	Alta
FEMA NFHL ArcGIS	Free	Zonas inundables oficiales	Flood Pro PENDIENTE	Muy alta (oficial)
OpenFEMA datasets	Free REST	NFIP claims, desastres	PENDIENTE	Alta (federal)
USGS Water Services	Free	Gauges / streamflow	PENDIENTE	Alta
NOAA CO-OPS	Free	Nivel mar / marea TX	ChannelWatch live parcial	Alta
Open-Meteo	Free	Weather + AQI modelado	ChannelWatch live	Media-alta
NOAA ATLAS 14	Free/bulk	Precipitacion design	PENDIENTE	Alta (ingenieria)

3.2 Aire / emisiones / energia

Fuente	Auth	Uso	Estado suite	Validacion
EPA AirNow	Free key	AQI tiempo real	Opcional Channel/Sentinel	Alta
OpenAQ API	Free key	Monitores ambient	Connector Sentinel	Alta
EPA CAMPD	Free key	CEMS plantas	Parcial/demo Sentinel	Alta
EIA Open Data	Free key	Gen/demanda/fuels	PENDIENTE Power/Sentinel	Muy alta
EPA GHGRP	Bulk CSV	GHG facilities	Demo/bulk path	Alta
EPA eGRID	Bulk	Emission rates	PENDIENTE	Alta
EPA TRI / Envirofacts	API/bulk	Releases toxicos	Demo Channel	Alta
TCEQ open GIS	Free services	Inventarios TX	Parcial	Alta (estatal)
ERCOT public	Varies/ToS	Grid TX	Demo PowerPulse	Media (ToS)

3.3 Permisos / negocios / geo

Fuente	Auth	Uso	Estado suite	Validacion
data.texas.gov (Socrata)	Free	Franchise tax ~3.3M	BizFinder bulk	Alta
TABC mixed beverage	Free Socrata	Alcohol receipts	BizFinder join	Alta
Austin SODA	Free (+token)	Building permits	ingest texas	Alta
Dallas Open Data	Free	Permits	ingest texas	Alta
San Antonio CKAN	Free	Permits	ingest texas	Alta
US Census Geocoder	Free	Batch lat/lon	PermitRadar	Alta
Zippopotam / Census	Free	ZIP geocode	MapHub/Channel	Media
OpenFreeMap tiles	Free	Map style	Todas map apps	Media

Como obtener keys free (pasos)

- EIA: <https://www.eia.gov/opendata/register.php> -> EIA_API_KEY
- AirNow: <https://docs.airnowapi.org/> -> AIRNOW_API_KEY
- OpenAQ: <https://openaq.org/> -> OPENAQ_API_KEY
- CAMPD: <https://www.epa.gov/power-sector/cam-api-portal> -> CAMPD_API_KEY
- Socrata app token (opcional rate limit): data.texas.gov / city portals
- NWS: NO key; solo User-Agent descriptivo con contacto
- FEMA NFHL: services publicos ArcGIS (URL FeatureServer en docs FEMA)

4. Donde HACER SCRAPER (y donde NO)

Scraping solo cuando: (a) no hay API/open data, (b) el dueño publica datos para uso público, (c) se respeta robots.txt, rate limits, y ToS, (d) se cachea en warehouse, (e) hay fallback.

4.1 Scraping JUSTIFICADO / ya en uso

Houston Permitting Center - weekly Permit Activity Reports (xlsx)

URL / origen: <https://www.houstonpermittingcenter.org/sold-permits-search>

Producto: PermitRadar ingest CLI + GitHub Actions semanal

Página HTML con links a .xlsx; parse openpyxl/xlrd; geocode Census; upsert Supabase. Riesgo: cambio de markup o bloqueo DNS. Mitigar: selectors flexibles + alertas de fallos.

TCEQ CAMS daily summary / EER emission events

URL / origen: Sitios TCEQ (URLs en config sources.yaml ChannelWatch)

Producto: ChannelWatch FastAPI collectors (best-effort + fixture fallback)

HTML frágil. Preferir migrar a TCEQ GIS/open data cuando exista capa equivalente.

DuckDuckGo HTML / search (descubrimiento de websites de leads)

URL / origen: Servicio DDG + Playwright deep analysis

Producto: TxBizFinder website research (1 job concurrente)

Rate limit agresivo; no es dato gubernamental. Uso interno lead-gen.

ERCOT public dashboards (si no hay feed JSON estable)

URL / origen: Páginas públicas ERCOT de demanda/condiciones

Producto: PowerPulse PENDIENTE

Revisar términos antes de scrape; preferir EIA series como proxy nacional/regional.

4.2 Scraping POSIBLE (bajo valor o alto riesgo) - evaluar caso a caso

- TCEQ TAMIS (marcado planned en Sentinel) - preferir open data
- Portales municipales sin SODA/CKAN (ciudades chicas TX) - xlsx/PDF semanal
- Wayback Machine (API existe; no scrapear UI) para historico de dominios
- Listings comerciales de terceros (Yelp, etc.) - EVITAR (ToS + legal)

4.3 NO scrapear (usar API/bulk oficial)

- FEMA flood maps / MSC - usar NFHL MapServer/FeatureServer
- EPA AQS/CAMPD/TRI - APIs y bulk oficiales
- EIA - Open Data API
- NWS - api.weather.gov (no scrapear weather.gov HTML)
- data.texas.gov / Socrata cities - SODA JSON, no HTML tables
- Sitios de aseguradoras privadas o paywalled MLS - fuera de scope

4.4 Patron de implementacion de scrapers

- Worker Python CLI (python -m ingest ...) + cron/Actions - nunca en request HTTP del browser
- Idempotencia: tabla ingest_runs con checksum de archivo/URL
- Timeouts, retries exponential, User-Agent honesto con contacto
- Almacenar raw en data/raw/ y processed en Postgres
- Fixture/demo fallback si falla (ya en Channel EER y varios connectors)
- Monitoreo: data_runs / last_success visible en UI About o /api/meta/runs
- Legal: robots.txt, no sobrecargar, no eludir CAPTCHA/paywall

5. Mayor validacion - checklist por capa de datos

Para cada fuente, documentar en la UI (About) y en meta API:

- Nombre de la fuente + URL oficial + fecha de ultima actualizacion (asOf)
- Cadencia (tiempo real / diario / semanal / anual)
- Licencia o ToS resumida
- Campos transformados vs crudos
- Flag demo:true cuando el dato es sintetico o ilustrativo
- Error rates del scraper en 7d
- Comparacion spot-check: muestra de 20 registros vs portal oficial

Niveles de confianza sugeridos en UI

- Official (verde): FEMA NFHL, NWS alert, OpenFEMA, EIA series
- Agency open data (azul): Socrata city permits, data.texas.gov, USGS
- Best-effort scrape (ambar): Houston xlsx, TCEQ HTML
- Modeled / demo (gris): scores sinteticos, IsolationForest labels, ZIP3 map

6. Mapa producto -> fuente prioritaria

Producto	Prioridad API/open data	Scrape
FloodGuard	FEMA NFHL + NWS + USGS + OpenFEMA	Solo si falta capa local no expu
PowerPulse	EIA + ERCOT public (ToS) + NOAA heat	ERCOT HTML solo fallback
ChannelWatch	Open-Meteo + NOAA + AirNow + TCEQ GIS	CAMS/EER HTML actual
Emissions Sentinel	EIA + CAMPD + OpenAQ + GHGRP/eGRID bulk	Evitar scrapes ad-hoc
PermitRadar	SODA/CKAN multi-city + Houston xlsx	Houston xlsx (ya)
TxBizFinder	data.texas.gov + TABC Socrata	DDG/Playwright research
MapHub	Proxy a APIs de la suite (no inventa datos)	N/A

7. Plan de 30 dias (ejecutable)

- 1. Semana 1: Registrar EIA + AirNow + OpenAQ; cablear Power/Channel; badges Official/Demo en UI
- 2. Semana 2: Integrar FEMA NFHL FeatureServer (lookup por lat/lon + ZIP centroid) en Flood Pro path
- 3. Semana 3: OpenFEMA claims aggregate por ZIP; USGS gauges en mapa Flood/Channel
- 4. Semana 4: Gateway API keys + rate limit + Stripe skeleton; OpenAPI del suite overview

8. Referencias de documentacion en repos

- texas-biz-finder/docs/DATA_SOURCES_PUBLIC.md
- texas-biz-finder/docs/SUITE_SAAS.md
- texas-biz-finder/docs/SAAS_PLATFORM_REPORT.md
- */docs/SUITE_SAAS.md en cada producto
- World Monitor (inspiracion UX/API, no copiar codigo AGPL a ciegas): github.com/koala73/worldmonitor

Aviso legal: este roadmap es plan de ingenieria. Los datos de riesgo de inundacion, red electrica y emisiones son informativos. No constituyen determinacion FEMA, consejo de seguros, ni instrucciones operativas de ERCOT/TCEQ/EPA. Validar siempre con fuentes oficiales y profesionales licenciados.